

1. Постановка проблемы

Современные системы вопрос-ответа (Question Answering, QA), основанные на архитектуре Retrieval-Augmented Generation (RAG), достигли значительных успехов в задачах, где ответ содержится в одном или нескольких семантически близких фрагментах текста [7]. Однако они демонстрируют систематические ограничения при решении multi-hop вопросов – запросов, требующих логического соединения фактов, распределённых по разным документам или разделам корпуса [10, 12].

Такие вопросы особенно распространены в предметно-ориентированных доменах: корпоративной поддержке, финансах, юриспруденции, здравоохранении, где связи между сущностями (например, «проект → технология → лаборатория») носят структурированный характер. В этих условиях классический RAG, опирающийся исключительно на плотный векторный поиск, часто извлекает релевантные, но недостаточные фрагменты, что приводит к неполным или галлюцинированным ответам [5, 14, 17].

Более того, отсутствие явного моделирования связей затрудняет атрибуцию источников и трассируемость выводов, что критично для доверенных ИИ-систем [7, 13]. Таким образом, возникает необходимость в гибридных подходах, которые объединяют преимущества семантического поиска с структурной выразительностью графов знаний (Knowledge Graphs, KG).

Эта работа направлена на решение следующей проблемы:

Как параметры графа знаний в GraphRAG-системах (тип связей, плотность, глубина обхода, стратегия ранжирования) влияют на качество ответов (precision, faithfulness) и вычислительную эффективность по сравнению с базовым RAG, особенно в контексте multi-hop рассуждений.

2. Литературный обзор

2.1. Эволюция RAG и её ограничения

Первой фундаментальной работой, заложившей основу современного RAG, стала публикация Lewis et al. (2020) [7], предложившая архитектуру,

сочетающую Dense Passage Retrieval (DPR) и генерацию на основе BART. Этот подход продемонстрировал значительный прирост точности (~10–15% по EM) на бенчмарках типа Natural Questions, но оставался ограниченным плоским представлением текста.

Несмотря на последующие улучшения (гиперпараметрическая настройка, ре-ранкинг, query expansion), flat-text RAG не решает проблему рассуждений через связи. Как показывают Han et al. (2025) [10], такие системы эффективны на простых, одношаговых запросах, но их производительность резко падает при увеличении сложности вопроса.

2.2. Появление GraphRAG: концепция и мотивация

Для преодоления этих ограничений исследователи начали интегрировать графы знаний в пайплайн RAG. Обзор Peng et al. (2024) [4] формализует GraphRAG как трёхэтапный процесс:

- индексация на основе графа,
- извлечение с направлением графа,
- генерация с улучшением через граф.

Такой подход позволяет явно моделировать зависимости между сущностями, что критически важно для multi-hop QA. Например, Edge et al. (2024) [2] демонстрируют, что иерархический GraphRAG с community detection обеспечивает на 72–83% более полные ответы по сравнению с векторным RAG при анализе крупных корпусов.

2.3. Методологические направления

Существующие GraphRAG-системы можно классифицировать по способу интеграции графа:

Гибридные архитектуры (HybridRAG [4], Barry et al. [9]) параллельно выполняют векторный и графовый поиск, затем объединяют контексты. Такой подход показывает превосходство над каждым компонентом по отдельности, особенно в финансовых доменах.

Граф-ограниченная генерация (Luo et al., 2025 [8]) вводит механизм KG-Trie, который ограничивает декодирование LLM только допустимыми

путями в графе, достигая нулевого уровня галлюцинаций на multi-hop задачах.

Адаптивные стратегии (Clue-RAG [18], PolyG [31]) динамически выбирают глубину обхода и тип связей в зависимости от сложности запроса, оптимизируя баланс между качеством и затратами.

2.4. Оценка и открытые проблемы

Оценка GraphRAG выходит за рамки EM/F1. Ключевыми становятся:

- Faithfulness и hallucination rate [8, 14, 17],
- Source precision и citation accuracy [7, 13],
- Latency и token consumption [9, 18].

Однако остаются важные вызовы:

- Высокая стоимость построения и обхода графа [2, 17],
- Потери информации при извлечении триплетов [30],
- Отсутствие унифицированных бенчмарков (хотя недавно предложены GraphRAG-Bench [12] и PolyBench [31]),
- Нестабильность на простых запросах, где GraphRAG может быть избыточен [10, 12].

Список литературы

[1] Lewis et al., Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks, NeurIPS 2020.

[2] Edge et al., From Local to Global: A Graph RAG Approach to Query-Focused Summarization, Microsoft Research, 2024.

[4] Han et al., HybridRAG: Integrating Knowledge Graphs and Vector Retrieval Augmented Generation, ACM 2024.

[5] Peng et al., Graph Retrieval-Augmented Generation: A Survey, ACL 2024.

[8] Luo et al., Graph-constrained Reasoning: Faithful Reasoning on Knowledge Graphs with Large Language Models, ICML 2025.

- [9] Barry et al., GraphRAG: Leveraging Graph-Based Efficiency to Minimize Hallucinations in LLM-Driven RAG for Finance Data, 2025.
- [10] Han et al., RAG vs. GraphRAG: A Systematic Evaluation and Key Insights, SIGIR 2025.
- [12] Xiang et al., When to use Graphs in RAG: A Comprehensive Analysis for Graph Retrieval-Augmented Generation, 2025.
- [13] Hallucination Mitigation for Retrieval-Augmented Large Language Models: A Review, MDPI Mathematics, 2025.
- [14] Lavrinovics et al., Knowledge Graphs, Large Language Models, and Hallucinations: An NLP Perspective, 2025.