

Разработка алгоритма мультимодального реранкинга для RAG-систем

1. Аннотация

Исследование решает проблему низкой точности ранжирования в MRAG-системах при обработке PDF-страниц, содержащих текст и изображения. Первичный поиск успешно формирует топ кандидатов, но часто ошибочно упорядочивает релевантность изображений и текста в рамках одной страницы. Это приводит к формированию итогового контекста, содержащего нерелевантные изображения и фрагменты, что снижает точность генерации ответов. Существующие текстовые реранкеры игнорируют визуальные признаки, а прямое использование сложных VLM для описания контента оказывается непрактичным для бизнес-приложений. Цель работы - создать специализированный мультимодальный реранкер, который корректно переупорядочивает кандидатов после первичного поиска, повышая качество ранжирования при строгих ограничениях на латентность (p50/p95) и компактность (до 8 ГБ VRAM). Ключевое решение - дообучение и дистилляция компактной модели для эффективного инференса.

2. Введение

Современные документы (отчёты, статьи) часто содержат текст, таблицы и изображения вместе. RAG-системы хорошо работают с текстом, но плохо - с мультимодальными данными. При механическом разбиении документа на чанки разрушается связь между визуальным элементом и его текстовым описанием. Это приводит к ошибкам при поиске и, как следствие, к формированию нерелевантного контекста для языковой модели. Точность конечного ответа падает. Существующие подходы либо слишком ресурсоемки (используют большие MLLM), либо узкоспециализированы (только для графиков), либо не учитывают требований к производительности.

3. Обзор литературы (Related Work)

Развитие Retrieval-Augmented Generation (RAG) систем привело к появлению эффективных текстовых реранкеров, таких как кросс-энкодеры, которые успешно переупорядочивают документы после первичного поиска. Однако эти методы демонстрируют ограничение при работе со смешанными данными, где текст и изображения образуют единый смысловой контекст. Ошибка ранжирования таких мультимодальных страниц напрямую снижает точность финального ответа системы, что формирует центральную проблему данного исследования.

Проблема носит не только теоретический, но и практический характер. Механическая предобработка документов (разбиение на фрагменты по фиксированным правилам без учёта контекста) разрушает целостность визуальных элементов. В работе "Vision-Guided Chunking Is All You Need: Enhancing RAG with Multimodal Document Understanding" (2025 / arXiv) показано, что разрыв многостраничных таблиц или процедур между чанками делает их нечитаемыми для поисковых алгоритмов. Авторы решают проблему, используя мультимодальную LLM как "умный парсер", что повышает точность на внутреннем датасете с 0.78 до 0.89. Этот пример иллюстрирует общий вызов: классические текстовые методы неадаптированы к структурным особенностям мультимодальных данных.

Эффективность существующих методов при работе со сложным визуальным контентом остаётся низкой. Исследование "Benchmarking Multimodal RAG through a Chart-based Document Question-Answering Generation Framework" (2025 / arXiv) создало специализированный бенчмарк для оценки систем на основе графиков. Результаты показали несостоятельность текущих подходов: базовый метод имел нулевой Recall@5 для графиков, а предложенное решение достигло лишь 42.53%. Это экспериментально подтверждает актуальность задачи мультимодального реранкинга.

Первым логичным шагом в решении проблемы стала адаптация больших мультимодальных моделей (MLLM). В работе "MLLM IS A STRONG RERANKER:

ADVANCING MULTIMODAL RETRIEVAL-AUGMENTED GENERATION VIA KNOWLEDGE-ENHANCED RERANKING AND NOISE-INJECTED TRAINING" (2024 / arXiv) авторы продемонстрировали, что MLLM (LLaVA-13B), дообученная как бинарный классификатор релевантности "запрос-изображение" (Knowledge-Enhanced Reranking), значительно превосходит стандартные эмбеддеры, улучшая Recall@1 на датасете WebQA с 57.10% до 79.74%. Сильной стороной подхода является прямое использование семантических возможностей MLLM. Однако слабость заключается в высокой вычислительной сложности (13B параметров) и затратном инференсе, что затрудняет интеграцию в производственные пайплайны с требованиями низкой латентности.

Более сложные архитектуры делают реранкинг адаптивным. В исследовании "RELEVANCE ISN'T ALL YOU NEED: SCALING RAG SYSTEMS WITH INFERENCE-TIME COMPUTE VIA MULTI-CRITERIA RERANKING" (2025 / arXiv) предложен двухэтапный агент: первый LLM анализирует запрос и генерирует кастомный промпт с релевантными критериями оценки (глубина, авторитетность, свежесть), второй — исполняет его для реранкинга с помощью GPT-4o. Ключевой результат — переход от универсальной к контекстно-зависимой оценке. Недостаток — зависимость от дорогостоящих проприетарных моделей (GPT-4o) и высокая задержка из-за multi-turn взаимодействия.

Параллельно развиваются методы оптимизации процесса ранжирования. В работе "DynamicRAG: Leveraging Outputs of Large Language Model as Feedback for Dynamic Reranking in Retrieval-Augmented Generation" (2025 / arXiv) реранкер, обучаемый на фидбеке от LLM-генератора, не только сортирует документы, но и динамически определяет их оптимальное количество, увеличивая Exact Match на датасете HotpotQA с 36.4% до 48.4%. Сильная сторона - интеграция feedback loop для улучшения решения. Слабость - сложность обучения и необходимость размещения двух моделей (генератор и реранкер), что увеличивает требования к ресурсам.

Альтернативное направление - создание специализированных компактных эмбеддеров. Модель "LLaVE: Large Language and Vision Embedding Models with Hardness-Weighted Contrastive Learning" (2025 / arXiv) использует контрастное обучение с акцентом на сложных негативных примерах, повышая общую точность Precision@1 на датасете MMEB с 59.5% до 65.2%. Хотя этот подход улучшает качество первичного поиска, он не решает задачу точечного реранкинга top-k кандидатов, которая критична для RAG.

Таким образом, анализ эволюции методов показывает прогресс от текстовых моделей к сложным мультимодальным и адаптивным системам. Однако выявляются системные ограничения современных подходов:

Высокая ресурсоёмкость: Решения на основе крупных MLLM (13B+) или проприетарных LLM требуют значительных вычислительных ресурсов.

Неоптимальная архитектура: Отдельные методы фокусируются либо на улучшении эмбеддингов, либо на сложном многоэтапном ранжировании, но не предлагают целостного компактного решения для реранкинга.

Отсутствие баланса качества и производительности: Не существует специализированного мультимодального реранкера, который одновременно обеспечивал бы высокие метрики (Recall@k, nDCG@k, MRR) и работал с низкой латентностью (p50/p95) в ограниченных ресурсах (~8 ГБ VRAM).

Настоящее исследование направлено на устранение этих пробелов.

4. Метод

В рамках исследования была разработана и реализована модульная RAG-система, основанная на каскадной архитектуре, сочетающей лексический и семантический поиск. На первом этапе выполняется поиск по алгоритму BM25, после которого полученные кандидаты уточняются с помощью семантического би-энкодера E5. Для окончательного ранжирования топ-документов используется реранкинг на основе кросс-энкодера E5, который оценивает релевантность кандидатов запросу. Сформированный контекст передается в языковую модель YandexGPT 5 для генерации итогового ответа. Качество работы системы на всех этапах оценивается с помощью метрик Precision@k, Recall@k и MRR. В результате реализации создана рабочая система с веб-интерфейсом и API для тестирования, оснащенная модульной архитектурой, позволяющей интегрировать новые алгоритмы реранкинга, а также системой сбора метрик качества поиска.

5. Эксперименты

Экспериментальная часть исследования проводится в два этапа с целью последовательной валидации предложенного подхода. На первом этапе система тестируется на стандартном текстовом датасете SQuAD v2.0 для отладки базового пайплайна, включающего каскадный поиск (BM25 - E5) и текстовый реранкинг с использованием кросс-энкодера E5. Это позволяет установить текстовый бейзлайн и проверить корректность работы модульной архитектуры, системы сбора метрик и веб-интерфейса.

На втором этапе фокус смещается на мультимодальный сценарий. Для этого будет использован специализированный датасет, содержащий PDF-страницы с текстом и изображениями. На этих данных будет проведено сравнение разрабатываемого мультимодального реранкера с текстовыми бейзлайнами. Основными метриками для оценки качества ранжирования станут Recall@k, nDCG@k и MRR. Критически важной частью эксперимента станет оценка производительности: время инференса и

потребление видеопамяти (VRAM) будут измеряться на перцентилях p50 и p95, чтобы убедиться в соблюдении целевых ограничений (латентность и объём памяти до 8 ГБ VRAM). Цель - продемонстрировать, что предложенное мультимодальное решение обеспечивает значительный прирост в качестве ранжирования по сравнению с текстовыми аналогами, сохраняя при этом приемлемую для практического развёртывания производительность.

6. Заключение

В данной работе представлен подход к разработке мультимодального реранкера для RAG-систем, который устраняет ключевой недостаток текстовых методов - игнорирование визуального контекста. Предлагаемое решение нацелено на баланс между высокой точностью ранжирования и практической применимостью в системах с требованиями к низкой латентности и ограниченным ресурсам. Ожидается, что реализация и валидация данного подхода внесет вклад в развитие более надежных и эффективных систем интеллектуального поиска по сложным документам.

7. Обсуждение (Discussion)

Основным предметом для обсуждения станет выбор оптимальной базовой архитектуры для компактного реранкера и стратегии создания качественного обучающего датасета. Также будут рассмотрены потенциальные риски, такие как переобучение на специфический тип документов и сложность оценки истинной релевантности мультимодального контента. Успех работы может открыть путь к созданию более общих и адаптивных моделей для работы с любыми смешанными типами данных.

8. Литература / Источники

1. MLLM IS A STRONG RERANKER: ADVANCING MULTIMODAL RETRIEVAL-AUGMENTED GENERATION VIA KNOWLEDGE-ENHANCED RERANKING AND NOISEINJECTED TRAINING. 2024. *arXiv*.
2. RELEVANCE ISN'T ALL YOU NEED: SCALING RAG SYSTEMS WITH INFERENCE-TIME COMPUTE VIA MULTI-CRITERIA RERANKING. 2025. *arXiv*.
3. Yang, Y., Zhong, J., Jin, L., Huang, J., Gao, J., Liu, Q., Bai, Y., Zhang, J., Jiang, R., & Wei, K. (2025). Benchmarking Multimodal RAG through a Chart-based Document Question-Answering Generation Framework. *arXiv*.
4. LLaVE: Large Language and Vision Embedding Models with Hardness-Weighted Contrastive Learning. 2025. *arXiv*.
5. RAG-ANYTHING: ALL-IN-ONE RAG FRAMEWORK. 2025. *arXiv*.
6. Vision-Guided Chunking Is All You Need: Enhancing RAG with Multimodal Document Understanding. 2025. *arXiv*.
7. GroupRank: A Groupwise Reranking Paradigm Driven by Reinforcement Learning. 2025. *arXiv*.
8. Shen, W., Wang, M., Wang, Y., Chen, D., Yang, J., Wan, Y., & Lin, W. (2025). ARE WE ON THE RIGHT WAY FOR ASSESSING DOCUMENT RETRIEVAL-AUGMENTED GENERATION? *arXiv*.
9. Towards Mixed-Modal Retrieval for Universal. 2025. *arXiv*.
10. DynamicRAG: Leveraging Outputs of Large Language Model as Feedback for Dynamic Reranking in Retrieval-Augmented Generation. 2025. *arXiv*.
11. Blended RAG: Improving RAG Accuracy with Semantic Search and Hybrid Query-Based Retrievers. 2024. *arXiv*.