

4. Метод

В рамках исследования была разработана и реализована модульная RAG-система, основанная на каскадной архитектуре, сочетающей лексический и семантический поиск. На первом этапе выполняется поиск по алгоритму BM25, после которого полученные кандидаты уточняются с помощью семантического би-энкодера E5. Для окончательного ранжирования топ-документов используется реранкинг на основе кросс-энкодера E5, который оценивает релевантность кандидатов запросу. Сформированный контекст передается в языковую модель YandexGPT 5 для генерации итогового ответа. Качество работы системы на всех этапах оценивается с помощью метрик Precision@k, Recall@k и MRR. В результате реализации создана рабочая система с веб-интерфейсом и API для тестирования, оснащенная модульной архитектурой, позволяющей интегрировать новые алгоритмы реранкинга, а также системой сбора метрик качества поиска.

5. Эксперименты

Экспериментальная часть исследования проводится в два этапа с целью последовательной валидации предложенного подхода. На первом этапе система тестируется на стандартном текстовом датасете SQuAD v2.0 для отладки базового пайплайна, включающего каскадный поиск (BM25 - E5) и текстовый реранкинг с использованием кросс-энкодера E5. Это позволяет установить текстовый бейзлайн и проверить корректность работы модульной архитектуры, системы сбора метрик и веб-интерфейса.

На втором этапе фокус смещается на мультимодальный сценарий. Для этого будет использован специализированный датасет, содержащий PDF-страницы с текстом и изображениями. На этих данных будет проведено сравнение разрабатываемого мультимодального реранкера с текстовыми бейзлайнами. Основными метриками для оценки качества ранжирования станут Recall@k, nDCG@k и MRR. Критически важной частью эксперимента станет оценка производительности: время инференса и