

Контекстное понимание сленга и хэштегов в социальных сетях малыми LLM для улучшения анонимизации

Автор: Стрельницкая Татьяна Викторовна, группа J4240

Направление подготовки: 09.04.04 Программная инженерия

Аннотация

В данной статье исследуются методы контекстного понимания сленговых выражений и хэштегов в социальных сетях для повышения качества автоматической анонимизации и интерпретируемости коротких сообщений. В данной работе предлагается метод извлечения значений и синонимов сленговых выражений из небольшого числа коротких контекстов без дообучения моделей. Подход основан на использовании masked-token контекстных представлений, полученных с помощью компактных энкодер-моделей, и последующей кластеризации этих представлений для выявления различных значений сленгового термина. Проведен анализ зависимости качества интерпретации от числа доступных контекстов. Экспериментальные результаты показывают, что устойчивые семантические кластеры могут формироваться уже при наличии 30–50 контекстов, что делает предложенный метод перспективным для практических задач автоматической анонимизации, анализа текстов социальных сетей и повышения понимания коротких постов.

1. Введение

Социальные сети являются одним из основных источников коротких пользовательских текстов. Подобные сообщения, как правило, содержат сленговые выражения, хэштеги, нестандартные формы слов и особые языковые конструкции, значение которых сильно зависит от контекста. При этом длина сообщений зачастую не превышает одного или двух предложений, что приводит к недостатку информации для однозначной интерпретации смысла.

Корректная интерпретация сленга является ключевой для целого ряда прикладных задач, включая автоматическую анонимизацию текстов, повышение их читаемости, анализ тональности и модерацию контента. Особую сложность представляет многозначность сленговых выражений, когда одно и то же слово может использоваться в нескольких различных значениях в зависимости от контекста.

Современные большие языковые модели демонстрируют высокую способность к генерации определений и перефразированию неформальной лексики. Однако их использование связано с существенными вычислительными затратами и зачастую не подходит для сценариев, где требуется приватность, воспроизводимость и работа на ограниченных ресурсах. Кроме того, такие модели могут неявно усреднять значения слов и при этом они не предоставляют явного механизма для анализа полисемии.

В данной работе исследуется возможность использования компактных предварительно обученных языковых моделей без дообучения для извлечения значений сленговых выражений из ограниченного числа коротких контекстов. Основная идея заключается в использовании masked-token метода для получения контекстных представлений удаленного сленгового слова и последующей кластеризации этих представлений с целью выявления различных семантических употреблений.

Основными вкладами работы являются:

1. предложение метода извлечения значений сленга без дообучения моделей;
2. эмпирический анализ зависимости качества интерпретации от числа контекстов.

2. Обзор существующих решений

2.1 Контекстная интерпретация значений слов

Ряд исследований показал, что контекстуализированные эмбединги, получаемые с помощью моделей семейства BERT, содержат информацию о

значении слова в конкретном контексте. Кластеризация таких представлений позволяет выявлять различные смыслы одного и того же слова без использования размеченных данных.

Тем не менее, большинство существующих работ ориентировано на формальные тексты и длинные контексты, а также предполагает наличие большого числа примеров для каждого слова. Проблема извлечения значений сленговых выражений из коротких и шумных текстов остается недостаточно изученной.

2.2 Masked language models и семантическое представление

Masked language models обучаются предсказывать скрытые токены на основе окружающего контекста, что делает их естественным инструментом для восстановления семантического содержания удаленного слова. Скрытое представление в позиции [MASK] может рассматриваться как вектор ожидаемого значения слова в данном контексте.

Несмотря на это, masked-token представления редко используются для систематического анализа сленга и полисемии в условиях ограниченного числа контекстов.

2.3 Генерация определений и нормализация сленга

Существующие методы обработки сленга в основном фокусируются на задаче нормализации, сопоставляя сленговые формы стандартным словам с использованием размеченных корпусов. Более новые подходы используют LLM для генерации определений и пояснений, однако такие методы требуют крупных моделей и не обеспечивают явного учета многозначности.

Таким образом, существует разрыв между мощными, но ресурсоемкими методами и легкими, интерпретируемыми решениями, пригодными для практического использования.

3. Методология

3.1 Сбор и подготовка данных

На первом этапе из исходного корпуса коротких сообщений отбираются тексты, содержащие целевое сленговое выражение. Далее сленговый токен заменяется на специальный маркер [MASK], формируя анонимизированную версию текста.

Данный шаг позволяет одновременно решить задачу анонимизации и подготовить данные для masked-token метода.

3.2 Контекстные представления

С помощью предварительно обученной модели BERT извлекается скрытое представление в позиции [MASK]. Этот вектор интерпретируется как контекстно-зависимое семантическое представление удаленного сленгового слова.

Для оценки числа различных значений сленгового выражения применяется кластеризация эмбедингов с автоматическим выбором числа кластеров. Перебирается диапазон значений k , для каждого из которых вычисляется silhouette score. Значение k , максимизирующее эту метрику, принимается в качестве оценки числа значений.

3.3 Кластеризация контекстов

После выбора оптимального числа кластеров выполняется кластеризация методом k-means. Каждый кластер интерпретируется как отдельное значение сленгового выражения, а центроид кластера используется как агрегированное представление этого значения.

3.4 Декодирование смысла кластеров

Для повышения интерпретируемости результатов используется два подхода.

Во-первых, центроиды кластеров сравниваются с эмбедингами слов из словаря модели, что позволяет получить список ближайших по смыслу лемм.

Во-вторых, для каждого кластера отбираются наиболее репрезентативные контексты, близкие к центроиду. Эти примеры могут использоваться для последующей генерации кратких определений с помощью генеративных моделей.

3.5 Анализ зависимости качества от числа контекстов

Для изучения устойчивости метода проводится серия экспериментов с увеличением числа контекстов N . Для каждого значения N фиксируются показатели качества кластеризации и стабильность числа выявленных значений.

4. Эксперименты

Эксперименты проводятся на корпусе коротких сообщений из социальных сетей, содержащих распространенные английские сленговые слова. Используется компактная предварительно обученная модель BERT-base-uncased без дообучения. В качестве основных метрик рассматриваются silhouette score, устойчивость кластеров и интерпретируемость результатов.

5. Результаты

Результаты показывают, что при очень малом числе контекстов (менее 10) семантическая структура выражена слабо. Однако при увеличении числа примеров до 50-70 формируются устойчивые и интерпретируемые кластеры.

Masked-token представления демонстрируют более высокое качество кластеризации по сравнению с sentence-level эмбедингами, особенно для многозначных сленговых выражений.

Полученные результаты подтверждают, что masked-token метод является эффективным инструментом для извлечения семантики сленга в условиях ограниченного контекста. Метод не требует дообучения, масштабируется на новые выражения и может быть интегрирован в практические системы анонимизации и анализа текста.

Основными ограничениями подхода являются чувствительность к шумным данным и зависимость от качества исходного корпуса.

6. Заключение

В работе предложен метод извлечения значений и синонимов сленговых выражений из коротких текстов с использованием компактных языковых моделей без дообучения. Экспериментальные результаты показывают, что даже при ограниченном числе контекстов возможно выявление устойчивых семантических значений, что делает предложенный подход перспективным для широкого круга прикладных задач.